

参考: ① bilibili

② <<快速理解SVM算法>>

③ <<统计学习方法>>

李航.

笔记记录者: Little H

## 序列最小优化算法 SMO (Sequential Minimal Optimization)

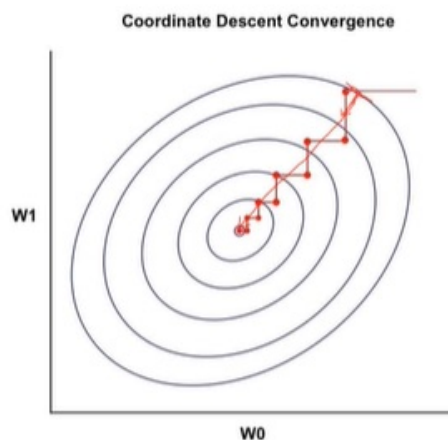
解如下凸二次规划的对偶问题

$$\begin{cases} \min_{\alpha} \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j K(x_i, x_j) - \sum_{i=1}^N \alpha_i \\ \text{s.t.} \quad \sum_{i=1}^N \alpha_i y_i = 0 \\ 0 \leq \alpha_i \leq C, \quad i=1, 2, \dots, N \end{cases}$$

整体又新, 复杂度会非常高

Note: 变量是拉格朗日乘子  $\alpha_i$ , 一个对应一个样本.

## 坐标下降



For example, on iteration  $k$  we select a variable  $j_k$  and set

$$w_{j_k}^{k+1} = w_{j_k}^k - \alpha_k \nabla_{j_k} f(w^k),$$

a gradient descent step on coordinate  $j_k$  (other  $w_j$  stay the same).

在传统的梯度下降中, 我们寻找每个等高线的切线位置(梯度),

对每个参数求偏, 得到整体导数, 会比较复杂, 考虑使用坐标下降.

坐标下降: 每一次只在一个坐标轴上修正.

## 序列最小最优化算法

- SVM的对偶问题是有约束二次凸优化问题
- 每次最少要调整两个变量

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j K(x_i, x_j) - \sum_{i=1}^N \alpha_i \quad \alpha_i \downarrow \downarrow \alpha_i + \nu \\ \text{s.t.} \quad & \sum_{i=1}^N \alpha_i y_i = 0 \quad \alpha_1 + \alpha_2 + \dots + \alpha_N = 0 \\ & 0 \leq \alpha_i \leq C, \quad i=1, 2, \dots, N \end{aligned}$$

$$\alpha_1 + \alpha_2 + \dots + \alpha_N = 0$$

若只对 $\alpha_1$ 做修正, 其余不变, 则得到  $\alpha_1 + \alpha_2 + \dots + \alpha_N \neq 0$

因此, 不能一次只更新一个 $\alpha$ , 每次至少要调整2个变量.

$\alpha_k (k \neq i, j)$ : fixed

$\alpha_i, \alpha_j$

以上, 凸优化问题被转化为子问题。

## 两个变量二次规划的求解过程

- 选择两个变量, 其它变量固定
- SMO将对偶问题转化成一列子问题:

$$\begin{aligned} \min_{\alpha_1, \alpha_2} \quad & W(\alpha_1, \alpha_2) = \frac{1}{2} K_{11} \alpha_1^2 + \frac{1}{2} K_{22} \alpha_2^2 + y_1 y_2 K_{12} \alpha_1 \alpha_2 \\ & - (\alpha_1 + \alpha_2) + y_1 \alpha_1 \sum_{i=3}^N y_i \alpha_i K_{i1} + y_2 \alpha_2 \sum_{i=3}^N y_i \alpha_i K_{i2} \\ \text{s.t.} \quad & \alpha_1 y_1 + \alpha_2 y_2 = - \sum_{i=3}^N y_i \alpha_i = \zeta \\ & 0 \leq \alpha_i \leq C, \quad i = 1, 2 \end{aligned}$$

$\alpha_1 y_1 = \alpha_2 y_2 + \zeta$   
 $d = \alpha_2 y_1 y_2 + \zeta y_1$


因此, 优化问题可以有解析解!




## 两个变量二次规划的求解过程

- 两个变量, 约束条件用二维空间中的图形表示


$$\begin{aligned} \alpha_1 y_1 + \alpha_2 y_2 &= k' \\ \alpha_1 + (-\alpha_2) &= k' = k' \cdot y_1 \\ \alpha_1 + \alpha_2 &= k \quad \alpha_2 = C \end{aligned}$$



$$y_1 \neq y_2 \Rightarrow \alpha_1 - \alpha_2 = k$$



$$y_1 = y_2 \Rightarrow \alpha_1 + \alpha_2 = k$$



$$0 < \alpha_2 < C$$

$$\begin{aligned} x &= a \\ x &\in [b, c] \\ x &= c \text{ 最优} \\ x &= 0 \end{aligned}$$

$$\alpha_1 y_1 + \alpha_2 y_2 = k$$

$$\textcircled{1} \quad y_1 \neq y_2 :$$

两边同乘以 $y_1$ , 则

$$\alpha_1 \cdot y_1^2 + \alpha_2 \cdot y_1 \cdot y_2 = k \cdot y_1$$

$$\alpha_1 - \alpha_2 = k' = k \cdot y_1$$

②  $y_1 = y_2$  :

两边同乘以  $y_1$ , 则

$$\alpha_1 \cdot y_1^2 + \alpha_2 \cdot y_1 y_2 = k y_1$$

$$\alpha_1 + \alpha_2 = k' = k y_1$$




## 两个变量二次规划的求解过程

- 根据不等式条件  $\alpha_2^{new}$  的取值范围:

$$L \leq \alpha_2^{new} \leq H$$

$$L = \max(0, \alpha_2^{old} - \alpha_1^{old}) \quad H = \min(C, C + \alpha_2^{old} - \alpha_1^{old})$$



考虑 Case 1:

$$\alpha_1 - \alpha_2 = k,$$

$$\Rightarrow \alpha_2 = \alpha_1 - k, \alpha_1 \in [0, C]$$

$$\text{则 } \alpha_1 - k \in [-k, C - k]$$

$$\text{又 } k = \alpha_1 - \alpha_2, \text{ 即 } \alpha_2 = \alpha_1 - k$$

$$\therefore \begin{cases} \alpha_2 \in [\alpha_2 - \alpha_1, C + \alpha_2 - \alpha_1] \\ \alpha_2 \in [0, C] \end{cases}$$

下界 L

上界 H

$$L = \max(0, \alpha_2^{old} - \alpha_1^{old})$$

$$H = \min(C, C + \alpha_2^{old} - \alpha_1^{old})$$




## 两个变量二次规划的求解过程

- 根据不等式条件  $\alpha_2^{new}$  的取值范围:

$$L \leq \alpha_2^{new} \leq H$$

$$L = \max(0, \alpha_2^{old} + \alpha_1^{old} - C) \quad H = \min(C, \alpha_2^{old} + \alpha_1^{old})$$



Case 2:  $\alpha_1 + \alpha_2 = k$

$$\Rightarrow \alpha_2 = k - \alpha_1$$

$$\alpha_1 \in [0, C]$$

$$k - \alpha_1 \in [k - C, k - 0]$$

$$\therefore \begin{cases} \alpha_2 \in [k - C, k], \text{ 即 } \alpha_2 \in [\alpha_1 + \alpha_2 - C, \alpha_1 + \alpha_2] \\ \alpha_2 \in [0, C] \end{cases}$$

$$\text{又 } \alpha_2 \in [0, C]$$

$$L = \max(0, \alpha_1^{old} + \alpha_2^{old} - C), \quad H = \min(C, \alpha_1^{old} + \alpha_2^{old})$$

通过由表优先, 获得

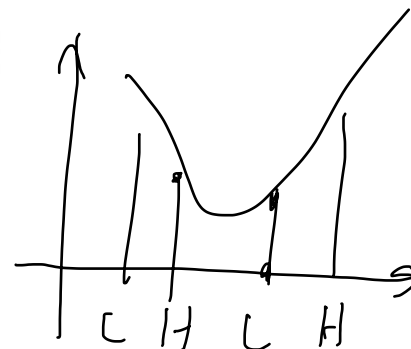
$$\alpha_1^{new, un}, \alpha_2^{new, un}$$

un: 未经剪辑



# 两个变量二次规划的求解过程

- 求解过程：
- 先求沿着约束方向未经剪辑时的  $\alpha_2^{new,unc}$
- 再求剪辑后的  $\alpha_2^{new}$



记：  $g(x) = \sum_{i=1}^N \alpha_i y_i K(x_i, x) + b$

令：  $E_i = g(x_i) - y_i = \left( \sum_{j=1}^N \alpha_j y_j K(x_j, x_i) + b \right) - y_i, \quad i = 1, 2$

$E$  为输入  $x$  的预测值和真实输出  $y$  的差,  $i = 1, 2$



# 两个变量二次规划的求解过程

引进记号

$$v_i = \sum_{j=3}^N \alpha_j y_j K(x_i, x_j) = g(x_i) - \sum_{j=1}^2 \alpha_j y_j K(x_i, x_j) - b, \quad i = 1, 2$$

目标函数写成：

$$W(\alpha_1, \alpha_2) = \frac{1}{2} K_{11} \alpha_1^2 + \frac{1}{2} K_{22} \alpha_2^2 + y_1 y_2 K_{12} \alpha_1 \alpha_2$$

前面：  $\alpha_1 y_1 + \alpha_2 y_2 = \zeta$

$$-(\alpha_1 + \alpha_2) + y_1 v_1 \alpha_1 + y_2 v_2 \alpha_2$$

由  $\alpha_1 y_1 = \zeta - \alpha_2 y_2$  及  $y_i^2 = 1$

$$\alpha_1 = (\zeta - y_2 \alpha_2) y_1$$







## 两个变量二次规划的求解过程

- 得到只是 $\alpha_2$ 的函数的目标函数

$$\begin{aligned} W(\alpha_2) = & \frac{1}{2}K_{11}(\zeta - \alpha_2 y_2)^2 + \frac{1}{2}K_{22}\alpha_2^2 + y_2 K_{12}(\zeta - \alpha_2 y_2)\alpha_2 \\ & - (\zeta - \alpha_2 y_2)y_1 - \alpha_2 + v_1(\zeta - \alpha_2 y_2) + y_2 v_2 \alpha_2 \end{aligned}$$

- 对 $\alpha_2$ 求导:  $\frac{\delta W}{\delta \alpha_2} = K_{11}\alpha_2 + K_{22}\alpha_2 - 2K_{12}\alpha_2 - K_{11}\zeta y_2 + K_{12}\zeta y_2 + y_1 y_2 - 1 - v_1 y_2 + y_2 v_2$

- 令其为0:

$$\begin{aligned} (K_{11} + K_{22} - 2K_{12})\alpha_2 &= y_2(y_2 - y_1 + \zeta K_{11} - \zeta K_{12} + v_1 - v_2) \\ &= y_2[y_2 - y_1 + \zeta K_{11} - \zeta K_{12} + (g(x_1) - \sum_{j=1}^2 y_j \alpha_j K_{1j} - b) - (g(x_2) - \sum_{j=1}^2 y_j \alpha_j K_{2j} - b)] \end{aligned}$$



## 两个变量二次规划的求解过程

- 将 $\zeta = \alpha_1^{old} y_1 + \alpha_2^{old} y_2$ 代入:

$$\begin{aligned} (K_{11} + K_{22} - 2K_{12})\alpha_2^{new,unc} &= y_2((K_{11} + K_{22} - 2K_{12})\alpha_2^{old} y_2 + y_2 - y_1 + g(x_1) - g(x_2)) \\ &= (K_{11} + K_{22} - 2K_{12})\alpha_2^{old} + y_2(E_1 - E_2) \end{aligned}$$

- 将 $\eta = K_{11} + K_{22} - 2K_{12}$ 代入:

$$\alpha_2^{new,unc} = \alpha_2^{old} + \frac{y_2(E_1 - E_2)}{\eta}$$



# 两个变量二次规划的求解过程

- 得到:
- 最优化子问题沿约束方向未经剪辑的解:

$$\alpha_2^{new,unc} = \alpha_2^{old} + \frac{y_2(E_1 - E_2)}{\eta}$$

$$\eta = K_{11} + K_{22} - 2K_{12} = \|\Phi(x_1) - \Phi(x_2)\|^2$$

- 剪辑后的解

$$\alpha_2^{new} = \begin{cases} H, & \alpha_2^{new,unc} > H \\ \alpha_2^{new,unc}, & L \leq \alpha_2^{new,unc} \leq H \\ L, & \alpha_2^{new,unc} < L \end{cases}$$

- 得到 $\alpha_1$ 的解

$$\alpha_1^{new} = \alpha_1^{old} + y_1 y_2 (\alpha_2^{old} - \alpha_2^{new})$$



## 计算阈值 $b$ 和 $E_i$

完成两个变量的优化后, 重新计算 $b$ ,  $E_i$

由KKT条件, 如果  $0 < \alpha_1^{new} < C$

所对应的样例是一个支持向量, 落在分割边界上,  $y_1^2 \cdot g(x_1) = 1, y_1$

$$g(x) = \sum_{i=1}^N \alpha_i y_i K_{i1} + b = y_1$$

$$g(x_1) = y_1$$

$$b_1^{new} = y_1 - \sum_{i=3}^N \alpha_i y_i K_{i1} - \alpha_1^{new} y_1 K_{11} - \alpha_2^{new} y_2 K_{21}$$

$$E_i = g(x_i) - y_i = \left( \sum_{j=1}^N \alpha_j y_j K(x_j, x_i) + b \right) - y_i, \quad i = 1, 2$$

$$E_1 = \sum_{i=3}^N \alpha_i y_i K_{i1} + \alpha_1^{old} y_1 K_{11} + \alpha_2^{old} y_2 K_{21} + b^{old} - y_1$$



## 计算阈值 $b$ 和 $E_i$

$$\begin{aligned}
 b_1^{new} &= \left[ y_1 - \sum_{i=3}^N \alpha_i y_i K_{i1} \right] - \alpha_1^{new} y_1 K_{11} - \alpha_2^{new} y_2 K_{21} \\
 E_1 &= \sum_{i=3}^N \alpha_i y_i K_{i1} + \alpha_1^{old} y_1 K_{11} + \alpha_2^{old} y_2 K_{21} + b^{old} - y_1 \\
 y_1 - \sum_{i=3}^N \alpha_i y_i K_{i1} &= -E_1 + \alpha_1^{old} y_1 K_{11} + \alpha_2^{old} y_2 K_{21} + b^{old} \\
 b_1^{new} &= -E_1 - y_1 K_{11} (\alpha_1^{new} - \alpha_1^{old}) - y_2 K_{21} (\alpha_2^{new} - \alpha_2^{old}) + b^{old}
 \end{aligned}$$



## 计算阈值 $b$ 和 $E_i$

- 如果:

$$0 < \alpha_2^{new} < C$$

$$b_2^{new} = -E_2 - y_1 K_{12} (\alpha_1^{new} - \alpha_1^{old}) - y_2 K_{22} (\alpha_2^{new} - \alpha_2^{old}) + b^{old}$$

$$E_i^{new} = \sum_S y_j \alpha_j K(x_i, x_j) + b^{new} - y_i$$

- $S$ 是所有支持向量 $x_j$ 的集合

如果 $\alpha_1^{new}, \alpha_2^{new}$ 同时满足条件 $0 < \alpha_i^{new} < C, i = 1, 2$ , 那么 $b_1^{new} = b_2^{new}$ 。如果 $\alpha_1^{new}, \alpha_2^{new}$ 是0或者 $C$ , 那么 $b_1^{new}$ 和 $b_2^{new}$ 以及它们之间的数都是符合KKT条件的阈值, 这时选择它们的中点作为 $b^{new}$ 。





# 变量的启发式选择

- SMO算法在每个子问题中选择两个变量优化，其中至少一个变量是违反KKT条件的

非常关键，怎么选才好

## 1、第一个变量的选择：外循环

- 违反KKT最严重的样本点，
- 检验样本点是否满足KKT条件：

$$\alpha_i = 0 \leftrightarrow y_i g(x_i) \geq 1$$

$$0 < \alpha_i < C \leftrightarrow y_i g(x_i) \leq 1$$

$$\alpha_i = C \leftrightarrow y_i g(x_i) \leq 1$$

$$g(x_i) = \sum_{j=1}^N \alpha_j y_j K(x_i, x_j) + b$$



# 变量的选择方法

$$\alpha_2^{\text{new}} = \alpha_1^{\text{old}} + \frac{y_1(E_1 - E_2)}{\eta}$$

## 2、第二个变量的检查：内循环，

- 选择的标准是希望能使目标函数有足够大的变化
  - 即对应  $|E_1 - E_2|$  最大，即  $E_1, E_2$  的符号相反，差异最大
- 如果内循环通过上述方法找到的点不能使目标函数有足够的下降
- 则：遍历间隔边界上的样本点，测试目标函数下降
  - 如果下降不大，则遍历所有样本点
  - 如果依然下降不大，则丢弃外循环点，重新选择





# SMO算法

- 输入：训练数据集  $T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$   
 $x_i \in \mathcal{X} = R^n, y_i \in \mathcal{Y} = \{+1, -1\}, i = 1, 2, \dots, N$  , 精度  $\epsilon$

- 输出：近似解  $\alpha$

(1)取初值  $\alpha^{(0)} = 0$  , 令  $k = 0$

(2)选取优化变量  $\alpha_1^k, \alpha_2^k$  , 解析求解两个变量的最优化问题, 求得最优解  $\alpha_1^{(k+1)}, \alpha_2^{(k+1)}$  , 更新  $\alpha$  为  $\alpha^{(k+1)}$ ;

(3)若在精度  $\epsilon$  范围内满足停机条件

$$\sum_{i=1}^N \alpha_i y_i = 0$$

$$0 \leq \alpha_i \leq C, i = 1, 2, \dots, N$$

则转(4); 否则令  $k = k + 1$ , 转(2);

(4)取  $\hat{\alpha} = \alpha^{(k+1)}$

即 KKT 条件

$$y_i \cdot g(x_i) = \begin{cases} \geq 1, & \{x_i | \alpha_i = 0\} \\ = 1, & \{x_i | 0 < \alpha_i < C\} \\ \leq 1, & \{x_i | \alpha_i = C\} \end{cases}$$

$$g(x_i) = \sum_{j=1}^N \alpha_j y_j K(x_j, x_i) + b$$



# SMO算法

启发式算法，基本思路：

- 确定如果所有变量的解都满足此最优化问题的KKT条件，那么得到解；
- 否则，选择两个变量，固定其它变量，针对这两个变量构建一个二次规划问题，称为子问题，可通过解析方法求解，提高了计算速度。
- 子问题的两个变量：一个是违反KKT条件最严重的那个，另一个由约束条件自动

$$\alpha_1 = -y_1 \sum_{i=2}^N \alpha_i y_i$$

SMO算法包括两个部分：

- 求解两个变量二次规划的解析方法
- 选择变量的启发式方法